

# Stima e Filtraggio, Tesina 2

Davide Ghion, Matr. 1225841

Padova, 19 Giugno, 2020

## 1 Introduzione

### 1.1 Descrizione del modello

La tesina è stata basata su un modello epidemiologico che descrive l'evoluzione di una malattia in una popolazione in un determinato arco temporale. Il modello in questione è detto Suscettibili-Infetti-Recuperati (SIR). Per semplificare lo studio si è supposto che tutti i pazienti, dopo essere stati infettati, guariscano e non siano più suscettibili all'infezione, oppure muoiano. Dunque questo tipo di modello può essere applicato solo per le malattie che, determinando un'immunità permanente, non possono recidivare, come per esempio morbillo e varicella.

Il modello SIR è rappresentabile tramite tre funzioni non lineari che mettono in relazione il numero di persone sane o suscettibili  $S$ , infette  $I$  e guarite, o recuperate,  $R$ . Inoltre sono presenti due coefficienti  $b$  e  $k$  che descrivono rispettivamente il tasso di infezione e di guarigione

$$\begin{cases} \dot{S} = -b \cdot S \cdot I \\ \dot{I} = b \cdot S \cdot I - k \cdot I \\ \dot{R} = k \cdot I \end{cases} \quad (1)$$

### 1.2 Generazione delle misure

Prima quindi di poter applicare qualsiasi tipo di algoritmo di tracking, il sistema è stato inizializzato con delle condizioni iniziali: si è considerata una popolazione di 100 individui, di cui inizialmente almeno il 99% è sano e si è studiato l'andamento dell'infezione in un anno.

$$\begin{cases} S_0 = 99 \\ I_0 = 1 \\ R_0 = 0 \\ \theta = [b \ k]^T = [0.005 \ 0.01]^T \end{cases} \quad (2)$$

Una volta quindi scelti i valori di  $\theta$  si è fatto evolvere il modello:




Figura 1: Evoluzione modello (1), con condizioni iniziali (2)

Conforme alle richieste della consegna le misure sono state sporcate da un rumore di misura  $\omega$ , per semplicità si è scelto che il rumore si distribuisca secondo una normale di media nulla e deviazione standard  $\sigma_\omega = 5$ , di seguito viene mostrato il confronto tra le misure rumorose e quelle "pulite":




Figura 2:  $y(t) = I(t) + \omega$

## 2 Prima parte

Lo scopo della prima parte è quello di stimare il valore del parametro  $\theta = [b \ k]^T$  avendo a disposizione l'andamento degli infetti, il quale è affetto da rumore di misura  $\omega$ , cioè  $y(t) = I(t) + \omega$ , in altre parole si è interessati a calcolare

$$E_{\pi}(g) = \int g(x)\pi(x)dx \quad (3)$$

che grazie alla approssimazione Monte Carlo dell'integrale si può esprimere come  $E_{\pi}(g) \approx \frac{1}{N} \sum_{i=1}^N g(x_i)$ . Si è scelto di usare l'algoritmo **Metropolis-Hastings** che permette di implementare una catena di Markov di  $m$  elementi con densità invariante pari alla posterior fornendo campioni correlati ma non indipendenti.

L'algoritmo è stato strutturato come segue:

1. la prima cosa di cui si ha bisogno è identificare una proposal density  $q(\cdot|\cdot)$  che permette di "pescare" dei nuovi candidati, si è scelto di usare il metodo *random walk* cioè  $q(\cdot|\cdot) = N(0, \Sigma^2)$ , con  $\Sigma = [\sigma_{prior_b} \ \sigma_{prior_k}]^T = [10^{-5} \ 5 \cdot 10^{-4}]^T$
2. si può dimostrare che la posterior può essere nota a meno di una costante di normalizzazione, cioè  $\pi(\cdot) \propto \text{likelihood} \cdot \text{prior}$ , per l'informazione a priori (la prior) di  $\theta$  si è considerata che si comporti come una normale di media nulla e varianza  $\sigma^2 = 3$ .

Rimane allora di calcolare la likelihood, si è scelto di usare la log-likelihood

$l_x$  per evitare problemi dovuti all'aritmetica finita e per efficienza numerica, cioè si è implementata la formula

$$l_x = -\frac{N}{2}\ln(2\pi) - \frac{N}{2}\ln(\sigma_w^2) - \frac{1}{2} \sum_{i=1}^{T=365} \left(\frac{\hat{x} - y}{\sigma_w}\right)^2 \quad (4)$$

Dunque il calcolo della posterior diventa

$$\pi(x) \propto l_x + \log(\text{prior})$$

Questo viene usato sia per il candidato  $c$  che per la misura di partenza  $x$ .

3. grazie alla scelta della proposal tramite *random walk*, la probabilità di accettare il nuovo candidato si semplifica diventando

$$\alpha(c, x) = \min\left(1, \frac{\pi(c)}{\pi(x)}\right) = \min(1, \exp^{\pi(c) - \pi(x)}) \quad (5)$$

In questo modo, considerata una variabile aleatoria uniforme  $u$  in  $[0,1]$ , decido di accettare il nuovo candidato se

$$u \leq \alpha(c, x)$$

quindi aggiorna la catena con il nuovo candidato o rimanendo alla posizione precedente.

Si propone ora un esempio di come funziona l'algoritmo, sono state scelte  $m = 1000$  iterazioni, il target è stato settato  $\theta = [5 \cdot 10^{-4} \quad 10^{-2}]^T$  e si è partiti con un guess iniziale nullo  $\hat{\theta} = [0 \quad 0]^T$




Figura 3: Convergenza di  $\hat{\theta}$  tramite M-H




Figura 4: Istogramma delle marginali proposte da M-H

### 3 Seconda parte

In questa parte quello che si vuole fare è andare a stimare (da cambiare?), tramite Particle Filter, gli andamenti dei parametri S,I,R avendo a disposizione le misure degli infetti nel corso del tempo.

#### 3.1 Discretizzazione del modello

Considerando il modello della consegna in forma di stato discreto, si è reso necessario adattare (1) discretizzandolo. Dunque come tipologia di discretizzazione è stata scelta *Eulero in avanti* anche se avrebbe potuto presentare problemi di instabilità

$$y_{n+1} = y_n + T \cdot h(t_n, y_n) \quad , \quad T \in \mathbb{N} \quad (6)$$

Dunque il modello (1) discretizzato diventa

$$\begin{cases} S_{t+1} = S_t + T \cdot (-b \cdot S_t I_t) \\ I_{t+1} = I_t + T \cdot (b \cdot S_t I_t - k \cdot I_t) \\ R_{t+1} = R_t + T \cdot (k \cdot I_t) \end{cases} \quad (7)$$

#### 3.2 Setup parametri e condizioni iniziali

Come descritto nella sottosezione (1.2) per prima cosa si sono rese disponibili tutte le misure, da notare però che è stato usato il modello discretizzato (7), inoltre è stato scelto come passo di campionamento  $T = 1$ .

#### 3.3 Particle Filter

L'obiettivo proposto è stato quello di implementare un particle filter che possa approssimare la pdf posterior ( $\pi(x)$ ) degli stati S,I,R tramite misure casuali rappresentate da campioni random (particelle) con pesi associati:

$$p(x_k | y_{0:k}) \approx \sum_{i=1}^{N_s} w_k^i \delta(x_k - x_k^i) \quad (8)$$

È fondamentale allora capire come scegliere e aggiornare le particelle ed i loro pesi  $\{x_{0:k}^i, w_k^i\}_{i=1}^{N_s}$ , con  $N_s$  il numero di particelle.

**Importance Sampling** Dato che non è possibile estrarre le particelle  $x_k^i$  dalla  $\pi(x)$  allora si identifica una proposal density  $q(x)$  da cui è possibile farlo, inoltre considero un'ulteriore pdf  $p(x)$  dalla quale è difficile estrarre i campioni ma per cui si può calcolare  $\pi(x)$ , allora la posterior vale

$$p(x) \approx \sum_{i=1}^{N_s} w^i \delta(x - x^i) \quad , \quad w^i \propto \frac{\pi(x^i)}{q(x^i)} \quad (9)$$

In particolare si è scelto di usare il metodo del *random walk* anche per questa parte e quindi si è considerata la proposal come una normale di media e varianza scelte nel momento dell'esecuzione del codice. Considerando le condizioni iniziali, durante i vari test, si è scelto di partire da delle distribuzioni abbastanza precise ed accurate.

**Sequential Importance Resampling** Definito il numero di particelle  $N_s$  allora si può procedere con l'algoritmo di predizione e aggiornamento degli stati della posterior:

1. si procede con l'estrazione delle particelle dalla mia proposal e vengono fatte evolvere secondo il modello (7), quindi ho l'approssimazione al tempo  $t$  degli stati S,I,R
2. assegno alle particelle i pesi secondo la formula

$$w_k^i \propto w_{k-1}^i \frac{p(y_k|x_k^i)p(x_k|x_{k-1}^i)}{q(x_k|x_{k-1}^i, y_k)} \stackrel{q(x_k|x_{k-1}^i, y_k)=p(x_k|x_{k-1}^i)}{=} w_{k-1}^i p(y_k|x_k^i)$$

3. i pesi vengono normalizzati in modo che la loro somma sia sempre unitaria:  

$$\sum_i w_k^i = 1$$
4. viene eseguita la stima dello stato tramite media pesata delle particelle

$$P_{tot} = \sum_{j=1}^{N_s} w_j^i \quad , \quad \hat{x}^i = \frac{1}{P_{tot}} \sum_{s=1}^{N_s} x_s^i w_s^i$$

5. viene fatto il resample delle particelle per evitare effetti di degenerazione, si è optato per un algoritmo che utilizza la somma cumulativa dei pesi e verifica l'intervallo in cui si trova il campione recuperandone gli indici

Viene ora mostrato un esempio dell'applicazione dell'algoritmo appena discusso, si è scelto  $N_s = 1000$ , le condizioni iniziali scelte sono:

$$\left\{ \begin{array}{l} S_0 = 99 \\ I_0 = 1 \\ R_0 = 0 \\ prior \sim N\left( \begin{bmatrix} 90 \\ 5 \\ 5 \end{bmatrix}, \begin{bmatrix} 0.5 \\ 1 \\ 0.5 \end{bmatrix} \right) \end{array} \right.$$




Figura 5: Stima stocastica del PF per lo stato composto dai parametri S,I,R






Figura 6: Focus dell'andamento degli infetti stimati dal PF

## 4 Riferimenti

1. A discrete SIR infectious disease model,  
[https://mathinsight.org/discrete\\_sir\\_infectious\\_disease\\_model#:~:text=The%20model%20contains%20three%20state,have%20nonnegative%20numbers%20of%20individuals](https://mathinsight.org/discrete_sir_infectious_disease_model#:~:text=The%20model%20contains%20three%20state,have%20nonnegative%20numbers%20of%20individuals))  
 .
2. Forecasting seasonal influenza with a state-space SIR model,  
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5623938>
3. Comments on the resampling step in particle filtering,  
[https://pingpong.chalmers.se/public/pp/public\\_noticeboard\\_attachment/fetch?messageId=35447&fileId=827809](https://pingpong.chalmers.se/public/pp/public_noticeboard_attachment/fetch?messageId=35447&fileId=827809)